С целью оценки информативности отклонения от плоскостности петель векторной электрокардиограммы (ВЭКГ), для петель QRS-комплекса и ST-сегмента, был разработан алгоритм извлечения признаков, характеризующих плоскостность. Отклонение ВЭКГ-петель от плоскости рассматривается как интегральная характеристика пространственной неоднородности процессов деполяризации и реполяризации миокарда и может служить чувствительным диагностическим признаком при анализе патологических состояний сердца [1]. Петля QRS-комплекса у людей с нормальным сердцебиением лежит приблизительно в одной плоскости, что говорит о возможной информативности признака при диагностике различных патологий [2, 3]. В случае петли Т-зубца отклонение от плоскостности может указывать на инфаркт миокарда [4, 5], однако по другим заболеваниям исследования практически отсутствуют.

Предобработка

В качестве входных данных используются многоканальные записи ЭКГ с фиксированной частотой дискретизации 500 Гц. Для анализа были выбраны следующие отведения: два первых стандартных отведения I и II, шесть грудных отведений V1-V6, т.к. они являются линейно независимыми [6].

Процесс снятия ЭКГ часто сопровождается значительным количеством шумов, главным образом мышечными артефактами, артефактами движения электродов и дрейфом базовой линии [7, 8]. Каждое отведение подвергается стандартной предобработке, включающей:

а) удаление постоянной составляющей, достигаемое вычитанием среднего значения сигнала, что снижает влияние смещения изолинии;

б) фильтрацию полосно-пропускающим фильтром Баттерворта с частотами среза от 0,6 до 60 Гц, которая подавляет низкочастотные артефакты (дыхание, движение электродов) [9] и высокочастотный шум [10], сохраняя основные морфологические компоненты ЭКГ. Когда обработка сигнала производится с использованием фильтра низкого порядка ($n = 2$),

значительная часть сигнала (Т-зубец) теряется в отфильтрованном выходе, в связи с чем был выбран фильтр четвёртого порядка [11].

В результате формируется очищенный временной ряд для каждого отведения.

Для повышения устойчивости анализа к шуму и случайным вариациям проводится усреднение пяти последовательных сердечных циклов. Из последовательности кардиоциклов выбирается пять периодов, начиная со второго, с целью избежания переходных эффектов, каждый период выделяется симметрично относительно R-пика. Найденные периоды приводятся к одинаковой длине с помощью временной интерполяции и вычисляются итоговые значения как среднее арифметическое в каждой точке. В результате формируется усреднённый цикл ВЭКГ, обладающий более высокой репрезентативностью и меньшей чувствительностью к выбросам.

На основе предобработанных отведений производится восстановление трех ортогональных компонент ВЭКГ (X, Y, Z).

Каждая компонента вычисляется как линейная комбинация грудных и конечностных отведений с фиксированными коэффициентами по формулам 1-3:

$$\begin{aligned} \mathrm{X} = {} & 0{,}172 \cdot V_1 + 0{,}074 \cdot V_2 - 0{,}122 \cdot V_3 - 0{,}231 \cdot V_4 - \\ & - 0{,}239 \cdot V_5 - 0{,}194 \cdot V_6 - 0{,}156 \cdot I + 0{,}01 \cdot II, \end{aligned} \quad (1)$$

$$\begin{aligned} \mathrm{Y} = {} & 0{,}057 \cdot V_1 - 0{,}019 \cdot V_2 - 0{,}106 \cdot V_3 - 0{,}022 \cdot V_4 + \\ & + 0{,}041 \cdot V_5 + 0{,}048 \cdot V_6 - 0{,}227 \cdot I + 0{,}887 \cdot II, \end{aligned} \quad (2)$$

$$\begin{aligned} Z = {} & 0{,}229 \cdot V_1 + 0{,}31 \cdot V_2 + 0{,}246 \cdot V_3 + 0{,}063 \cdot V_4 - \\ & - 0{,}055 \cdot V_5 - 0{,}108 \cdot V_6 - 0{,}022 \cdot I - 0{,}102 \cdot II, \end{aligned} \quad (3)$$

где $V_1, V_2, V_3, V_4, V_5, V_6$ – значения разности потенциалов, регистрируемые в грудных отведениях;

I, II – значения разности потенциалов, регистрируемые в первом и втором стандартных отведениях соответственно.

Таким образом, в каждый момент времени ЭКГ представляется точкой в трехмерном пространстве, а сердечный цикл – замкнутой пространственной кривой.

На следующем шаге производится выделение QRS и T петель. Для этого используется автоматическая разметка, позволяющая определить границы сегментов.

Извлечение признаков

Для количественной оценки пространственной структуры петли используется модель аппроксимации плоскостью. Предполагается, что идеальная (строго планарная) петля может быть описана уравнением плоскости вида:

$$Z = a \cdot X + b \cdot Y + c, \tag{4}$$

где X, Y, Z – координаты точек петли в пространстве ВЭКГ.

На каждой петеле выделяются несколько точек, для каждой из которых создаются локальные окрестности различных размеров с центром в данной точке. Каждая из окрестностей аппроксимируется плоскостью, заданной уравнением 4, по методу наименьших квадратов. Качество аппроксимации характеризуется коэффициентом детерминации R^2, к рассчитывается по формуле 5:

$$R^2 = 1 - \frac{\sum_i (y_i - \widehat{y_i})^2}{\sum_i (y_i - \mu)^2}, \tag{5}$$

где y_i – фактические значения координаты;

$\widehat{y_i}$ – расчётные значения координат, аппроксимированных плоскостью;

μ – среднее значение.

Коэффициент интерпретируется следующим образом:

а) при $R^2 = 1$ петля идеально плоская;

б) при $R^2 \approx 0$ имеется выраженное отклонение от плоскостности.

В качестве признаков рассчитывается метрика R^2 для каждой петли в целом, а также значения для пяти окрестностей пяти равномерно расставленных точке вдоль петли. Таким образом, полученный вектор признаков для каждого пациента имеет размерность 52. Предполагается, что такой подход позволяет оценить локальные деформации петель и выявить участки наибольшего отклонения от плоскостности.

Методика применяется последовательно ко всем записям набора данных. Для каждого пациента формируется строка признаков, а итоговый результат представляется в виде табличной структуры (DataFrame).

В данной работе оценка модели производится для трёх различных патологий, для каждой из которых подготовлен отдельный набор данных. Характеристики датасетов представлены в таблице 1.

Таблица 1 – Характеристики наборов данных

Характеристика	Патология		
	Амилоидоз	Легочная гипертензия	Сниженная фракция выброса
Размерность	228	1244	1816
Процент класса 1, %	43	50	50
Доля тестовой выборки	0.2	0.2	0.2

Применение модели для диагностики различных патологий позволит оценить информативность признаков плоскостности петли при выявлении того или иного заболевания.

Применение алгоритмов машинного обучения для классификации

Целью данного этапа является оценка диагностической информативности рассчитанных признаков плоскостности петель ВЭКГ. Для этого используется supervised-подход с обучением и тестированием моделей машинного обучения, способных выявлять нелинейные зависимости между пространственными характеристиками ВЭКГ и целевой клинической меткой. Для данной задачи были выбраны модели Random Forest и Support Vector Machine (SVM).

Random Forest представляет собой ансамблевый метод, основанный на построении и объединении нескольких решающих деревьев с последующим агрегированием их предсказаний путём усреднения. Данный подход достаточно универсален, легко адаптируется к различным специальным задачам обучения и возвращает меры важности признаков [12].

Модель обучается на стандартизированных признаках с числом деревьев, равным 100, и ограниченной глубиной 20, что снижает риск переобучения. Каждое дерево строится на случайной подвыборке данных и случайном подмножестве признаков, что обеспечивает декорреляцию деревьев внутри ансамбля.

Помимо предсказания класса, модель формирует вероятностную оценку принадлежности к положительному классу, которая используется для построения PR-кривых и расчёта вероятностных метрик качества.

Вторая модель – метод опорных векторов – представляет собой набор связанных методов обучения с учителем, используемый для классификации и регрессии, относится к семейству обобщённых линейных классификаторов с нелинейным ядром [13]. Используется радиально-базисная функция (RBF), позволяющая эффективно разделять данные в пространстве высокой размерности.

Для учёта возможного дисбаланса классов используется взвешивание классов, при котором ошибки для миноритарного класса штрафуются сильнее.

Аналогично Random Forest, модель формирует вероятностные оценки, что позволяет использовать унифицированные метрики сравнения.

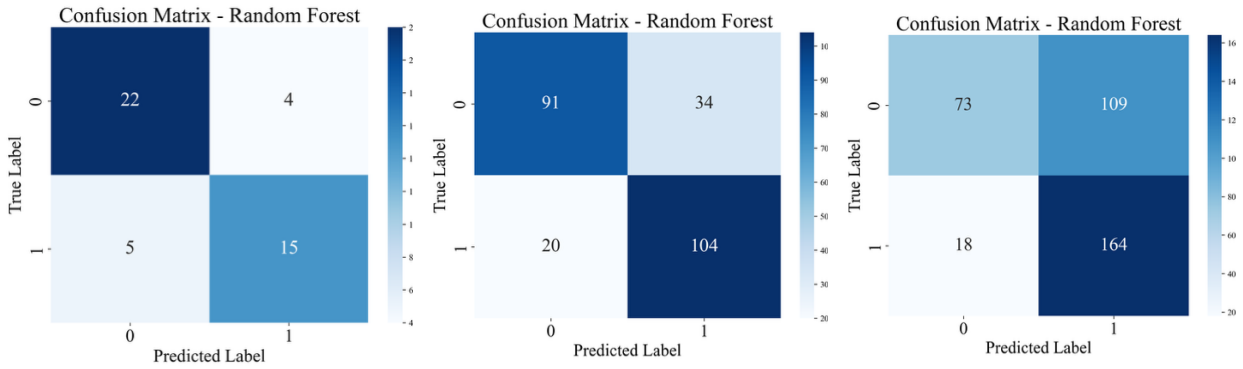
В качестве входных данных для моделей используются табличные признаки, сформированные на предыдущем этапе.

Результаты и интерпретация

В результате применения моделей Random Forest и SVM для классификации трёх патологических состояний были построены матрицы ошибок, PR-кривые и рассчитаны количественных метрики качества, а также важности признаков для модели Random Forest.

Использование двух алгоритмов машинного обучения, основанных на различных принципах принятия решений, позволяет оценить устойчивость полученных результатов и характер связи между признаками плоскостности ВЭКГ и каждой из патологий.

На рисунке 1 представлены матрицы ошибок для модели Random Forest.



а б в

а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

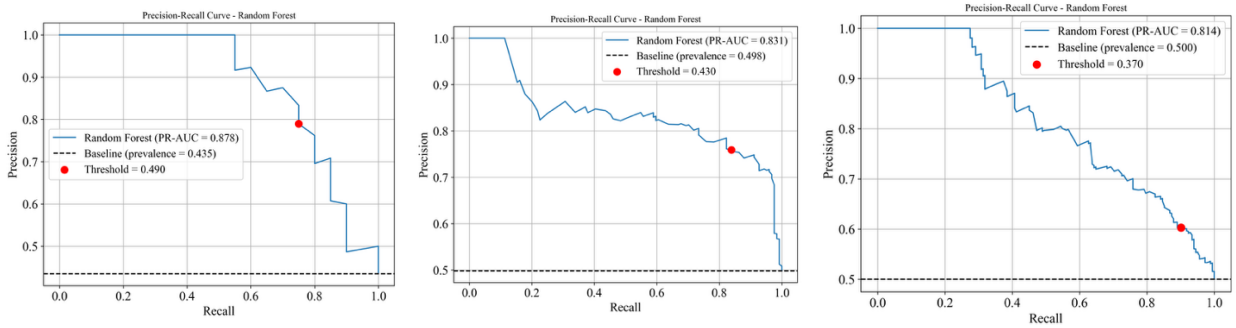
Рисунок 1 – Матрицы ошибок модели Random Forest для рассматриваемых патологий

Для амилоидоза (рисунок 1а) наблюдается относительно сбалансированное распределение ошибок между классами. Это указывает на способность модели выявлять как патологические случаи, так и примеры без амилоидоза.

В случае сниженной фракции выброса (рисунок 1в) заметно смещение ошибок в сторону одного из классов. Это может свидетельствовать о более выраженном перекрытии признаковых пространств для данной патологии.

Для лёгочной гипертензии (рисунок 1б) матрица ошибок демонстрирует наиболее симметричное распределение.

PR-кривые для модели Random Forest представлены на рисунке 2.



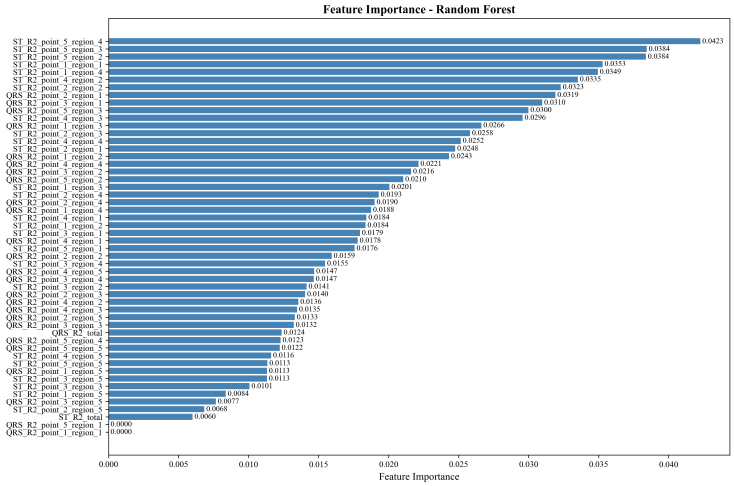
а б в

а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

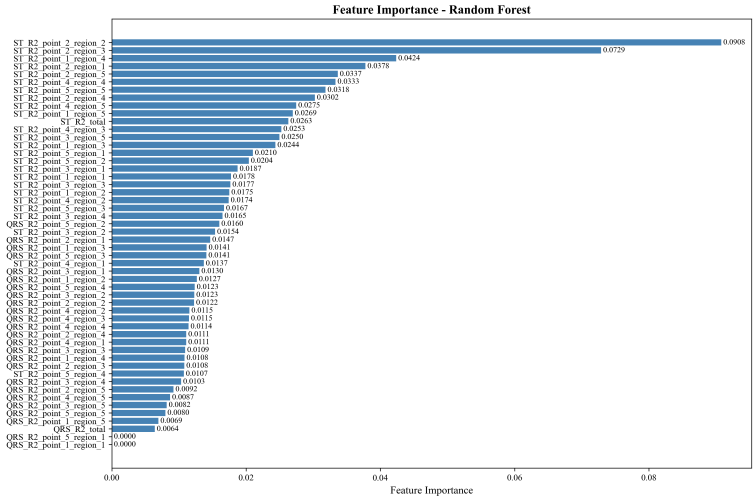
Рисунок 2 – PR-кривые модели Random Forest для рассматриваемых патологий

Форма PR-кривых указывает на хорошую дискриминационную способность модели для всех трёх патологий. Наиболее устойчивое разделение классов наблюдается для амилоидоза и лёгочной гипертензии. Для сниженной фракции выброса PR-кривая демонстрирует менее выраженное отклонение от диагонали, что отражает более сложный характер классификации данного состояния.

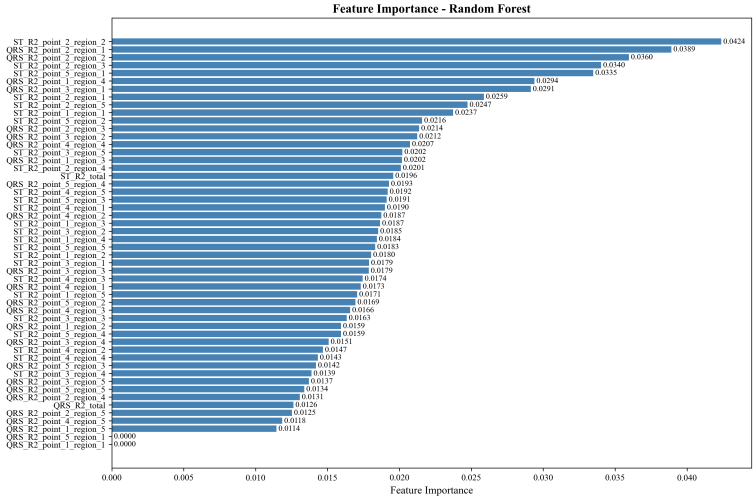
Гистограммы важности признаков Random Forest представлены на рисунке 3.



а



б



в

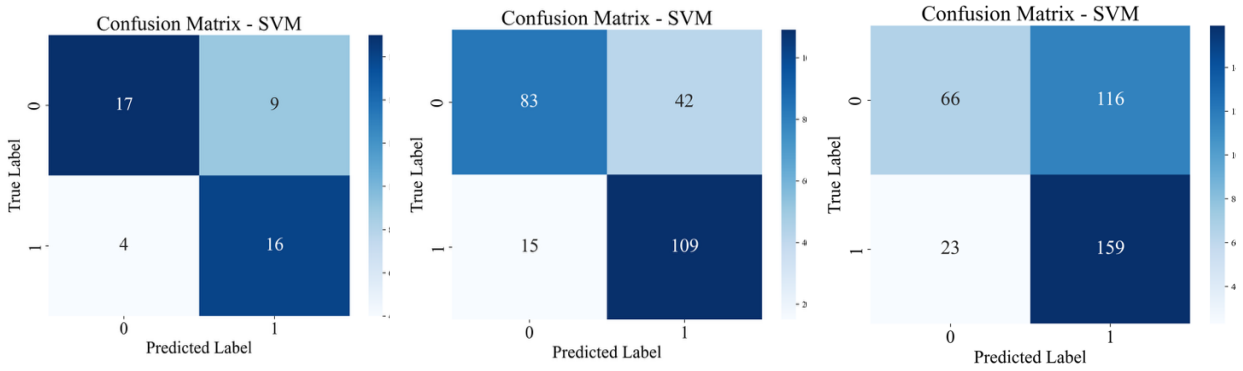
а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

Рисунок 3 – Гистограммы важности признаков модели Random Forest для рассматриваемых патологий

В случае амилоидоза и легочной гипертензии наибольший вклад в принятие решения вносят признаки плоскостности ST-сегмента. Для

сниженной фракции выброса отсутствует значительный перевес значимости отдельной петли ВЭКГ, однако значимость ST-сегмент также преобладает.

На рисунке 4 представлены матрицы ошибок для модели SVM.



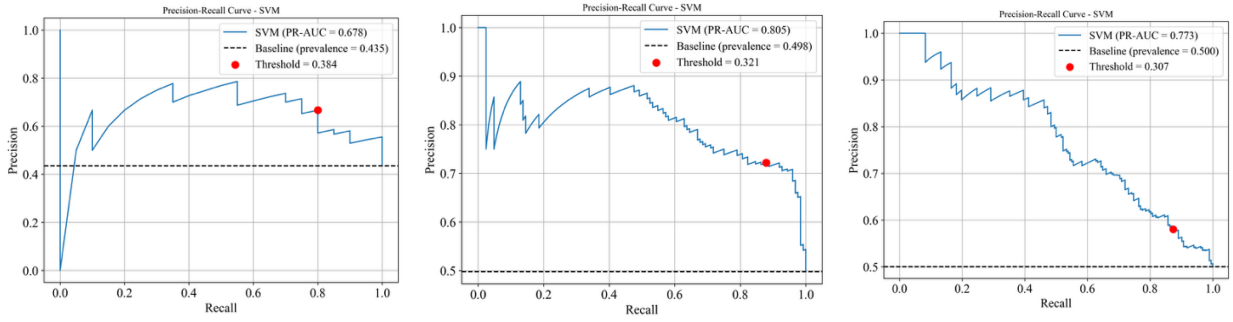
а б в

а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

Рисунок 4 – Матрицы ошибок модели SVM для рассматриваемых патологий

По сравнению с Random Forest, модель SVM демонстрирует более выраженную асимметрию ошибок для всех рассматриваемых патологий

На рисунке 5 представлены PR-кривые для модели SVM.



а б в

а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

Рисунок 5 – PR-кривые модели SVM для рассматриваемых патологий

Форма PR-кривых подтверждает, что модель сохраняет способность к нелинейному разделению классов, однако для всех патологий кривые расположены ближе к диагонали по сравнению с Random Forest. Это указывает на более низкую дискриминационную способность SVM в данной задаче.

В качестве метода интерпретации работы модели использовалась тепловая карта (heatmap) важности сегментов исходного ЭКГ сигнала. Каждой

точке heatmap сопоставляется скалярное значение, отражающее вклад данной точке во времени в принятие решения моделью.

Исходной информацией для построения служат важности признаков, полученные из модели Random Forest. Каждый признак ассоциирован с определённым сегментом сердечного цикла (QRS или ST) и с характерной окрестностью внутри сегмента. В зависимости от масштаба признака ему сопоставляется временной интервал внутри одного сердечного цикла. Таким образом, каждому признаку k ставится в соответствие временной интервал $\left[t_1^k, t_2^k\right]$ и его числовая важность ω_k.

Значение heatmap в фиксированный момент времени t определяется как сумма важностей всех признаков, временные интервалы которых покрывают данный момент. Иными словами, каждая точка heatmap аккумулирует вклад всех признаков модели, «активных» в этот момент времени. Значение суммарной важности точки можно рассчитать по формуле 6:

$$I(t) = \sum_{k:t\in\left[t_1^k, t_2^k\right]} \omega_k. \quad (6)$$

После вычисления суммарной важности для всех временных точек выполняется нормализация по максимальному значению согласно формуле 7:

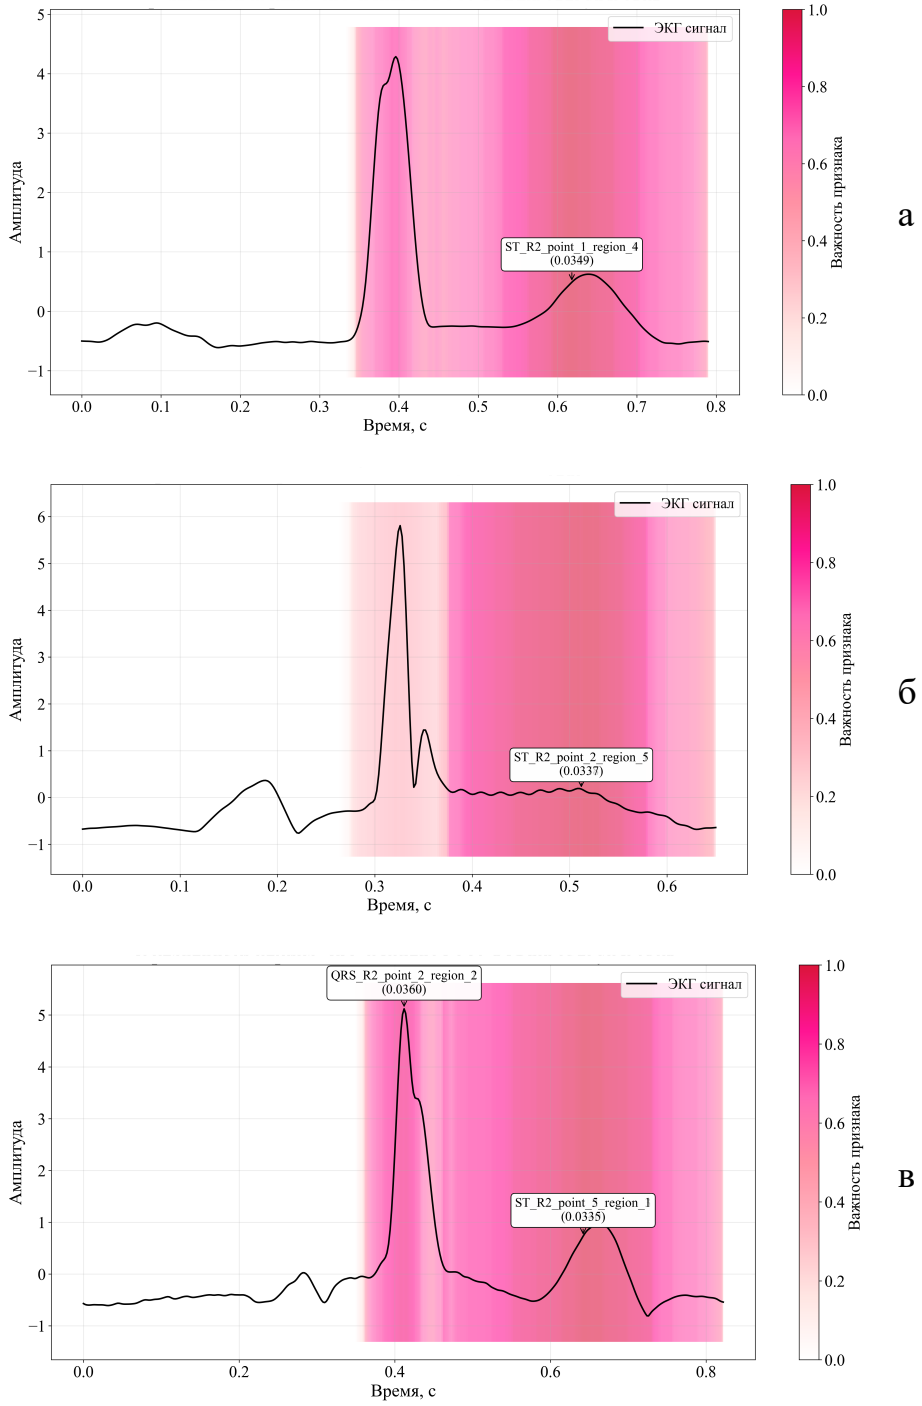
$$I_{norm}(t) = \frac{I(t)}{max_t I(t)}, \quad (7)$$

где $I(t)$ – суммарная важность всех признаков данной точки;

$max_t I(t)$ – максимальное значение суммарной важности по всем рассматриваемым точкам.

Это позволяет интерпретировать heatmap как относительную меру значимости различных фаз сердечного цикла и визуализировать её с помощью цветовой шкалы.

Полученные тепловые карты важности участков ЭКГ сигнала представлены на рисунке 6.



а – амилоидоз; б – лёгочная гипертензия; в – сниженная фракция выброса

Рисунок 6 – Тепловая карта важности участков исходного ЭКГ сигнала для рассматриваемых патологий

Из тепловых карт видно, что для различных патологий модель преимущественно акцентирует внимание на одной и той же фазе сердечного

цикла. Для амилоидоза и легочной гипертензии наиболее значимыми оказываются участки, соответствующие Т-зубцу. Важность данного участка соответствует 57 % от общей важности рассматриваемых сегментов для амилоидоза и 73 % для легочной гипертензии. Т-волна является наиболее нестабильной частью ЭКГ и обнаруживается изменённой при ряде нарушений сердечной активности [14], что соотносится с результатом интерпретации модели.

Амилоидоз характеризуется нарушением диастолической функции [15], которая на ЭКГ в свою очередь характеризуется интервалом TP [16].

Для сниженной фракции выброса вклад сравнительно больше распределён между QRS и ST-сегментом в соотношении 46 % и 54 % соответственно, однако бóльшая важность, аналогично другим патологиям, приходится на Т-зубец.

Модель в задаче бинарной классификации формирует для каждого объекта вероятность принадлежности к положительному классу. Для преобразования вероятностного прогноза в итоговое бинарное решение используется порог бинаризации. Стандартное значение порога обычно принимается равным 0.5, однако такой выбор не всегда является оптимальным.

В данной работе выбор порога осуществлялся на основе анализа кривой precision–recall. Для различных значений порога вычислялись метрики precision и recall, отражающие соответственно точность положительных предсказаний и полноту обнаружения положительного класса. На основе этих метрик рассчитывался F1-score – гармоническое среднее между precision и recall и позволяет учитывать баланс между этими двумя характеристиками. Оптимальным считался порог, при котором значение F1-score достигало максимума.

Подбор порога выполнялся только на обучающей выборке с использованием кросс-валидации. Такой подход позволяет избежать утечки информации из тестовой выборки и получить более устойчивую оценку

качества модели. После определения оптимального порога он применялся при классификации объектов тестовой выборки.

Для количественной оценки качества классификации моделей были рассчитаны метрики precision, recall, f1-score, accuracy (таблицы 2, 3).

Таблица 2 – Метрики обученной модели SVM

Метрика	Амилоидоз		Сниженная фракция выброса		Легочная гипертензия	
	для класса 0	для класса 1	для класса 0	для класса 1	для класса 0	для класса 1
Precision	0,810	0,640	0,742	0,578	0,847	0,722
Recall	0,654	0,800	0,363	0,874	0,664	0,879
F1-score	0,723	0,711	0,487	0,696	0,744	0,793
Accuracy	0,717		0,618		0,771	
Threshold	0,384		0,310		0,321	

Таблица 3 – Метрики обученной модели Random Forest

Метрика	Амилоидоз		Сниженная фракция выброса		Легочная гипертензия	
	для класса 0	для класса 1	для класса 0	для класса 1	для класса 0	для класса 1
Precision	0,815	0,789	0,802	0,601	0,820	0,754
Recall	0,846	0,750	0,401	0,901	0,728	0,839
F1-score	0,830	0,769	0,535	0,721	0,771	0,794
Accuracy	0,804		0,651		0,783	
Threshold	0,490		0,370		0,430	

Из таблиц видно, что модель Random Forest превосходит SVM по accuracy для всех трёх патологий. Наиболее выраженное преимущество наблюдается для амилоидоза и легочной гипертензии.

Полученные результаты показывают, что признаки плоскостности петель ВЭКГ обладают диагностической информативностью для различных патологий, однако характер этой информативности существенно зависит от типа заболевания. Амилоидоз и лёгочная гипертензия проявляют более выраженные и структурированные изменения пространственной организации ВЭКГ, и, несмотря на более низкую размерность набора данных, лучше поддаются классификации по данному вектору признаков, тогда как сниженная фракция выброса характеризуется более гетерогенным признаковым пространством.

Список использованных источников

1. Grant R. P. Spatial vector electrocardiography: A method for calculating the spatial electrical vectors of the heart from conventional leads //Circulation. – 1950. – Т. 2. – №. 5. – С. 676-695.

2. Tereshchenko L. G. et al. Analysis of speed, curvature, planarity and frequency characteristics of heart vector movement to evaluate the electrophysiological substrate associated with ventricular tachycardia //Computers in biology and medicine. – 2015. – Т. 65. – С. 150-160.

3. Choudhuri S. et al. Planarity of the spatial QRS loop of vectorcardiogram is a crucial diagnostic and prognostic parameter in acute myocardial infarction //Medical hypotheses. – 2019. – Т. 130. – С. 109251.

4. Yamauchi K. Computer analysis of vectorcardiograms in myocardial infarction with special reference to polar vector and planarity of the QRS and T loops //Japanese heart journal. – 1979. – Т. 20. – №. 5. – С. 587-601.

5. Karsikas M. et al. New Vectorcardiographic non-planarity measure of T-wave loop improves separation between healthy subjects and myocardial infarction patients //2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society. – IEEE, 2009. – С. 1754-1757.

6. Krasteva V., Jekova I., Schmid R. Simulating arbitrary electrode reversals in standard 12-lead ECG //Sensors. – 2019. – Т. 19. – №. 13. – С. 2920.

7. Wang Z. et al. Muscle and electrode motion artifacts reduction in ECG using adaptive Fourier decomposition //2014 IEEE International Conference on Systems, Man, and Cybernetics (SMC). – IEEE, 2014. – С. 1456-1461.